

Maîtrisez les bonnes pratiques de la data visualisation

#Comprenez l'importance de la représentation graphique

Aujourd'hui, les entreprises du monde entier génèrent un volume de données extrêmement important : plusieurs dizaines de zettaoctets (milliards de téraoctets) selon les dernières estimations. Et ce chiffre ne fait qu'augmenter exponentiellement au fur et à mesure que les technologies de stockage évoluent.

Il devient donc indispensable pour une entreprise d'avoir des outils pour analyser ces données, afin d'en **tirer des enseignements exploitables** au niveau business (des tendances d'achat selon les périodes, par exemple) et plus globalement, de pouvoir **surveiller les différentes activités de l'entreprise** afin d'identifier d'éventuels problèmes.

Toutes les librairies vues jusqu'à présent font partie de ces outils, mais demandent une certaine technicité, au moins en programmation. Or, la plupart des personnes en charge de la stratégie au sein d'une entreprise (ceux qu'on appelle les **décideurs**) n'ont généralement pas ce bagage.

Il faut donc un outil permettant de rendre la donnée accessible à ces personnes ?

Tout à fait ! C'est ce qu'on appelle la **data visualisation**, ou dataviz pour les intimes. La data visualisation est un ensemble de techniques utilisées pour communiquer des informations clés sur un gros volume de données, afin d'en faciliter la compréhension et la lecture pour tous. Ce domaine s'est vraiment démocratisé en entreprise dans les années 80, lorsque les entreprises ont pris conscience que l'analyse de leurs données pourrait aider grandement à la prise de décision !

“Une image vaut mille mots.”

Confucius

Lorsqu'il est question de représentation ou de graphique, de nombreux choix s'offrent à nous. On peut citer de façon non exhaustive :

les courbes pour représenter une évolution d'une caractéristique (comme la démographie d'un pays) dans le temps ;

les graphiques circulaires (appelés plus vulgairement des graphiques camemberts) pour représenter une répartition ;

ou encore des cartes lorsqu'on souhaite afficher une information géographique.

Il en existe bien d'autres, et je vous propose à présent de découvrir en détail les principales.

#Identifiez le graphique adapté

Le choix d'un graphique va énormément dépendre des différentes variables qu'on cherche à représenter, et de l'information dont on dispose.


#Présentez une évolution dans le temps

Ce cas se présente lorsqu'on souhaite représenter une **variable numérique** qui **évolue dans le temps** : la notion d'évolution implique qu'on ne peut avoir qu'une valeur numérique par pas de temps choisi – par mois, par année, etc.

	date	chiffre d'affaires
0	2012-01-01	27961
1	2012-02-01	25863
2	2012-03-01	25877
3	2012-04-01	22950


Data frame à expliciter en graphique

Pour représenter une évolution dans le temps, on peut utiliser **des diagrammes en ligne**, ou **en courbes** :



Exemple de diagramme en ligne

Mais également des **diagrammes à barres** :





Exemple de diagramme à barres


#Comparez différents groupes

On utilise ce type de graphique généralement lorsqu'on a des données agrégées sur une variable non numérique. On a ainsi une valeur numérique agrégée par groupe ou par catégorie :

	catégorie	quantité
0	Cat A	13000
1	Cat B	18690
2	Cat C	25000


Data frame à valeur numérique agrégée par quantité

Pour représenter cela, on peut utiliser des **diagrammes circulaires**, appelés plus vulgairement, dans la langue de Molière, des camemberts :



Exemple de diagramme circulaire

Mais l'idéal (comme nous le verrons un peu plus tard) reste tout de même les **diagrammes à barres** :




Autre exemple de diagramme à barres

#Représentez une distribution


Ce type de graphique est particulièrement utile lors d'une analyse préliminaire, lorsqu'on souhaite comprendre les données à disposition, et la façon dont chaque variable se répartit. Il y a deux cas possibles : une variable numérique et une variable non numérique.

Dans le cas d'une variable numérique, on utilise généralement un **histogramme** :



Exemple d'histogramme

Il existe aussi une variante de l'histogramme, appelée **diagramme à densité** :



Exemple de diagramme à densité

Dans le cas d'une variable non numérique, techniquement, c'est une visualisation que nous avons déjà rencontrée. Car la première étape est d'agréger les données pour compter le nombre d'occurrences au sein de notre variable, par catégorie ou groupe. Ensuite, on se retrouve simplement dans le cas de comparaison cité ci-dessus : on peut utiliser un **diagramme circulaire** ou un **diagramme à barres**.

#Représentez la relation entre 2 variables numériques


Le dernier cas, que nous n'avons pas traité mais qui est couramment rencontré, est le choix du graphique lorsqu'on souhaite représenter la relation entre deux variables numériques. Le jeu de données contient dans ce cas plusieurs lignes, exprimées sur (au moins) deux variables numériques :

	taille	poids
0	167	75.057288
1	168	67.407685
2	168	72.992274
3	186	73.843352
4	179	71.977984

Data frame mettant en relation 2 variables numériques

On peut tracer plusieurs points (un pour chaque ligne) en mettant l'une des variables en abscisse et l'autre en ordonnée : c'est ce qu'on appelle un **nuage de points** :





Exemple de nuage de points

La liste n'est naturellement pas exhaustive, et ce cours serait bien trop long s'il fallait tous les traiter, mais voici cependant un bon échantillon des principales que vous allez être amené à rencontrer.

#Cernez les bonnes pratiques de la dataviz


Maintenant que nous avons différents graphiques à notre portée, il est temps de faire un point sur la façon de réaliser ces graphiques, ce qu'on pourrait appeler : **les bonnes pratiques en data visualisation**.


Ce sont des "règles" simples qu'il est très vivement conseillé de suivre pour assurer la lisibilité et la compréhension des visualisations.

#1. Privilégiez la simplicité

Lorsqu'on travaille dans l'analyse de données, on est souvent amené à travailler avec de nombreuses variables. Il est assez tentant de toutes les mixer en un seul graphique, en jouant par exemple sur les couleurs, sur la taille des points, sur la forme des points, etc.

Voici un exemple :





Un graphique trop complexe présentant 5 informations

Nous avons sur ce graphique 5 informations qui sont représentées :

la taille en abscisse ;

le poids en ordonnée ;

le genre en couleur ;

le revenu via la taille des points ;

et le statut marital via la forme des points.


Pfiou...

Vous admettez que même si on peut arriver à le lire en s'aidant de la légende, ce graphique est un peu trop chargé d'informations. Il vaut mieux dans ce genre de cas faire plusieurs graphiques avec peu d'informations sur chacun, mais qui soient clairs et interprétables au premier coup d'œil !

#2. Clarifiez votre graphique

Il existe aujourd'hui de nombreuses représentations hyper stylées et complexes dans le monde de la data visualisation. Gardez à l'esprit que votre but premier, lors de la création d'une visualisation, est de rendre cette dernière la plus lisible possible. D'une certaine façon, un graphique doit être autosuffisant : n'importe qui doit être en mesure de le lire et de le comprendre, à partir des seuls éléments présents dessus et autour.


Laissez-moi imaginer cela. Considérons le graphique suivant :



Un exemple de graphique à clarifier

Il peut paraître sympa, mais... de quoi parle-t-on ? Quelles sont les informations représentées ? À quoi correspond chaque barre ? À quoi correspond chaque couleur ? Il manque beaucoup trop d'informations pour être en mesure de l'interpréter.

À présent, que dire de celui-ci :



Un graphique clarifié avec des titres, une légende et des valeurs pertinentes

C'est exactement le même graphique, sauf qu'à présent, nous avons la grille de lecture pour le lire et le comprendre. Qu'est-ce qui a rendu cela possible ?

Quatre choses :

Les titres des axes. On a même ici précisé l'unité !

La légende pour la compréhension des couleurs.


Le titre, qui nous indique clairement de qui et de quoi on parle.

Les valeurs indiquées au-dessus des barres pour éviter l'imprécision.

#3. Choisissez le graphique adéquat

Cela fait directement écho à la présentation des différents graphiques faite précédemment. Considérons le graphique suivant :






Un exemple de graphique inadapté

Nous avons la quantité en stock de chaque catégorie (A, B, C ou D) de différents produits.

Seriez-vous en mesure de dire dans quelle catégorie, entre B et C, nous disposons le plus de stock ?

Ce n'est pas évident, n'est-ce pas ? Prenons la même visualisation avec cette fois-ci un diagramme en barres :



Un graphique plus adapté pour permettre de comparer les stocks

La différence est d'un coup beaucoup plus nette, la catégorie C possède plus de stock que la catégorie B. Pourtant, ce sont exactement les mêmes données. C'est pour cela qu'un diagramme en barres est généralement plus avisé qu'un diagramme circulaire, à partir du moment où il y a plus de 2 groupes à comparer.

#En résumé

La **datavisualisation** est un ensemble de techniques utilisées pour représenter visuellement des informations clés sur un gros volume de données, afin d'en permettre la compréhension et l'analyse.

Pour représenter :

une évolution dans le temps, on privilégiera des diagrammes en barres ou des courbes ;

une comparaison entre différents groupes, on utilisera un diagramme circulaire ou un diagrammes en barres ;

une distribution, on privilégiera un histogramme ou un diagramme à densité ;

la relation entre 2 variables numériques, on développera un nuage de points.

Il existe quelques règles à observer pour réaliser un graphique efficace :

privilégier la simplicité, quitte à multiplier le nombre de graphiques ;

privilégier la clarté, en proposant le plus d'informations possible pour permettre au lecteur d'interpréter seul ce graphique ;

choisir le graphique adéquat en fonction de ce qu'on cherche à représenter.

Je vous propose à présent de créer ces différents graphiques avec Python en utilisant la librairie Matplotlib.